Multi Modal Agent Translator

Soutenance finale

Ala Boussoffara, Mahdi Ayadi, Nassereddine Abdelhakim, Soufien El Mazlouzi, Gildas Evano

May 22, 2025

Problématique client



Client : SOCOTEC Monitoring
Développer un agent conversationnel

> productivité

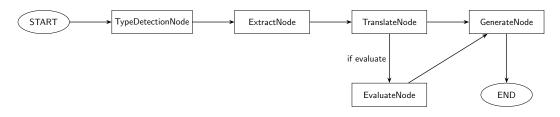
Principaux objectifs du projet

- 1. Conserver le format et la mise en page du document d'origine (pdf, word)
- 2. Traduire précisémment le vocabulaire technique du génie civil

Cadre de notre travail : preuve de concept qui sera reprise par un alternant

Pipeline LangChain

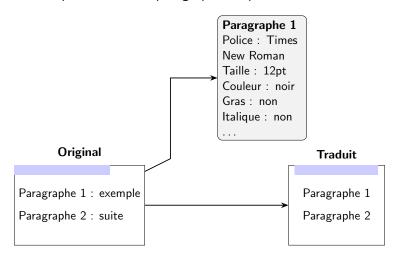
Description du traitement d'un fichier avec LangGraph 1:



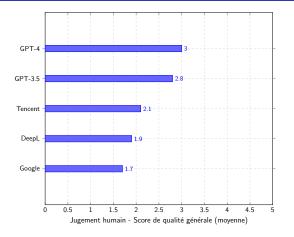
¹O. Topsakal and T. C. Akinci, "Creating Large Language Model Applications Utilizing LangChain: A Primer on Developing LLM Apps Fast"

Agents d'extraction et de génération

Détection de la police, taille et paragraphes imparfaite



Agent de traduction : utilisation d'un LLM



Source: Longyue Wang et al. Document-Level Machine Translation with Large Language Models. 2023. arXiv:2304.02210 [cs.CL]. https://arxiv.org/abs/2304.02210

Agent de traduction : utilisation d'un LLM

Prompt:

Predict the continuation of the translation into {self.target_language} for the current original chunk. Use the context so that the result concatenated with the previous translated chunk forms a coherent sentence.

IMPORTANT:

- Keep the approximate word count equal or lower.
- Detect if the chunk is part of a larger sentence and adjust accordingly.
- Use the last 20 words of the previous chunk and the first 20 words of the next chunk for context.
- If no logical continuation is possible, translate the chunk as a standalone sentence.
- Preserve non-translatable elements (links, emails, phone numbers, names, specialized terms) exactly.
- Preserve the original formatting (bullet points, numbered lists, headings, indentations).

CONTEXT:

Previous Translated Chunk: "{ prev_translated_escapedv}"

Previous Original Chunk (last 20 words): "{previous_original_chunk}"

Current Chunk: "{current_chunk}"

Next Original Chunk (first 20 words): "{next_original_chunk}"

OUTPUT ONLY the translated version of the current chunk

Agent de traduction

Comment améliorer la traduction des termes techniques ^a :

- X Fine-tuning d'un petit modèle Ollama
- X RAG d'exemples de traduction
- ✓ RAG de traductions issues d'un glossaire



^a Jiawei Zheng et al., Fine-tuning Large Language Models for Domain-specific Machine Translation, 2024, arXiv:2402.15061

Niveau	Vérification visuelle du niveau d'huile.	
Reniflard / filtre	Vérification de l'état des filtres (sans démontage).	
Silent bloc	Vérification de l'état des silent bloc (présence de poussière).	

Un exemple de vocabulaire problématique

Agent de traduction : RAG

Niveau	Vérification visuelle du niveau d'huile.	
Reniflard / filtre	Vérification de l'état des filtres (sans démontage).	\longrightarrow S'aider d'un glossaire : reniflard m blow-valve [on a boiler], breather pipe
Silent bloc	Vérification de l'état des silent bloc (présence de poussière).	\longrightarrow enrichir le prompt avec des traductions pertinentes

Un exemple de vocabulaire problématique

Agent d'évaluation

But : comparer objectivement les différentes versions de notre programme

 \rightarrow utilisation de COMET ²

²Ricardo Rei et al., COMET: A Neural Framework for MT Evaluation, 2020, arXiv:2009.09025

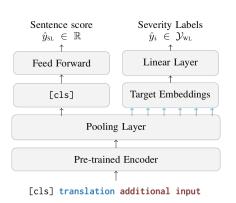
Agent d'évaluation

But : comparer objectivement les différentes versions de notre programme

ightarrow utilisation de COMET 2

Niveau de sévérité des mots:

$$\mathcal{Y}_{\mathsf{WL}} = \{\mathsf{OK}, \mathsf{MIN}, \mathsf{MAJ}, \mathsf{CRIT}\}$$



²Ricardo Rei et al., COMET: A Neural Framework for MT Evaluation, 2020, arXiv:2009.09025

Agent d'évaluation

Résultats

Fichier	sans RAG	RAG
Rapport d'audit technique	0.8478	0.8485
Rapport de vérification	0.7951	0.7967

Résultats

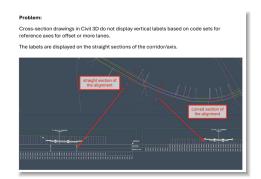
Fichier	sans RAG	RAG
Rapport d'audit technique Rapport de vérification		0.8485 0.7967

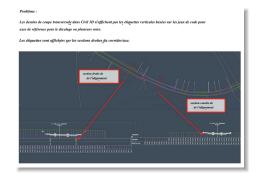
Hypothèses

- 1) Modification de sens trop subtile
- 2) Noyé dans le nombre de mots courants

Prototype de traitement OCR

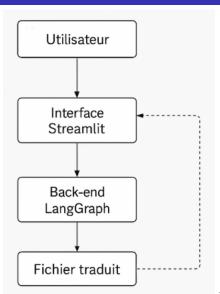
→ Difficultés rencontrées Preuve de faisabilité d'OCR :





Interface Streamlit

- Téléversement du fichier (PDF ou Word)
- Choix de la langue cible
- Démarrage de traduction
- Téléchargement du résultat



Résultat final

Démonstration

Perspectives



- Implémenter la parallélisation de la LangChain
- Mettre en place le fine-tuning, sur un plus gros corpus
- Réussir à utiliser un modèle d'évaluation de la traduction
- Corriger la génération après traitement OCR

État des livrables

- 1) Code commenté sur GitHub
- 2) Rapport de démarche
- 3) Rapport de fonctionnement

On ajoute une section qui contient le texte qui précède et qui succède, afin de donner du contexte au LLM, en espérant que cela améliore la qualité de la traduction.

Predict the continuation of the translation into (target_language) for the current original chunk. Use the context so that the result concutenated with the previous translated chunk forms a colsevent soutence. MPORTANT:

Keep the approximate word count equal or lower.

Detect if the chunk is part of a larger sentence and adjust accordingly.
 Use the last 20 words of the previous chunk and the first 20 words of the

If no logical continuation is possible, translate the clunk as a standalone sentence.
 Preserve non-translatable elements (links, emails, phone numbers, names, specialized tenne) assert.

Preserve the original formatting (bullet points, numbered lists, headings, indentations).
 CONTEXT:

Previous Translated Chunk: '{prev_translated_escaped}'
Previous Original Chunk (last 20 words): '{previous_original_chunk}'
Current Chunk: '{eurrent_ehunk}'

Next Original Chunk (first 20 words): "(next_original_chunk)" OUTPUT ONLY the translated version of the current chunk.

CITCI ONLI IN CHIMANIC WOOL II IN CI

5.2 RAG

Une des demandes très importantes de notre client était de traduire correctement les termes techniques contenus dans les Échies, ce qui pose problème avec les cuitis activals. Nous zons semmes approjes sur un article scientifique [5] qui s'attaque à ce problème et propose trois techniques utilisables conjointement pour améliorer la qualité de traduction sur des domaines apécifiques en utilisant ut. List. 1

- Faire du fine-tuning sur une base de données contenant des exemples de fichiers et leur traduction par un expert
- Ajouter au prompt des exemples de phrases traduites qui sont proches de la phrase à traduire
- Rempiacer directement dans la phrase à traduire les termes techniques par leur traduction issue d'un glossaire et demander au LLM de conserver es traductions préalables.
- Nons n'avons pas eu le temps de mettre en place la technique 1, mais nous aurions pu télécharger un petit modèle sorce Ollams et le fine-tuner sur le glossoire. La solution 2 n'était pas envisageable du fait du manque de données; par aïlleurs, plus d'exemples de fichiers traduits aumient su être mis à recôti tour le fine-tuninz.

Finalement, la solution 3 était la plus prometteuxe, d'où notre demande à Monsieur Jacquet d'avoir un glossaire de génie civil. L'approche naïve consisterait à avoir une liste de couples terres original : terre

Valeur ajoutée



Livrables 00

Responsables

Tâche	Contributions (%)
Structure pipeline LangChain	Ala: 100
Agent d'extraction Word/PDF	Gildas: 33 Ala: 33 Soufien: 33
Agent de traduction	Gildas: 40 Ala: 60
Interface Streamlit	Soufien: 100
RAG	Gildas: 100
Agent d'évaluation	Mahdi: 60 Hakim: 40
OCR	Gildas: 25 Ala: 37.5 Mahdi: 37.5
Présentation intermédiaire & finale	Gildas: 60 Ala: 10 Hakim: 10 Mahdi: 10
	Soufien: 10
Rapport de démarche & fonctionnement	Gildas: 100